Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____Радиотехнический_____

КАФЕДРА _____ИУ5_____

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

Прогнозирование цен на разные модели машин Ford

Студент ___РТ5-61Б___ _____ ____Столярова О.Д._
(Группа) (Подпись, дата) (И.О.Фамилия)

Руководитель _____ ___Гапанюк Ю.Е. ____
(Подпись, дата) (И.О.Фамилия)

Консультант _____ _____
(Подпись, дата) (И.О.Фамилия)

2022 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ

Заведующий кафедрой _______
(Индекс)

_____ _____
(И.О.Фамилия)

« _____ » _____ 20 ____ г.

З А Д А Н И Е
на выполнение научно-исследовательской работы

по теме _____Прогнозирование цен на разные модели машин марки Ford_____

_____

Студент группы ___РТ5-61Б____

_____Столярова Ольга Денисовна_____
(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)

_____учебная__________

Источник тематики (кафедра, предприятие, НИР) _____

График выполнения НИР: 25% к ___ нед., 50% к ___ нед., 75% к __ нед., 100% к ___ нед.

Техническое задание *__Решить задачу машинного обучения. Построить модели машинного обучения для решения задачи классификации. Должно быть выбрано не менее пяти моделей, две из которых должны быть ансамблевыми. Построить базовое решение для выбранных моделей без подбора гиперпараметров и решение с найденными оптимальными значениями гиперпараметров. Сравнить качество полученных моделей с качеством baseline-моделей. Оценить качество построенных моделей на основе выбранных метрик. Должно быть выбрано не менее трех метрик*_____

Оформление научно-исследовательской работы:

Расчетно-пояснительная записка на ____ листах формата А4.
Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

_____

_____

_____

Дата выдачи задания « ___ » _____ 20__ г.

Руководитель НИР _____ ___Гапанюк Ю.Е.___
(Подпись, дата) (И.О.Фамилия)

Студент _____ ___Столярова О.Д.___
(Подпись, дата) (И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

Содержание

1. Введение

Машинное обучение разделяется на несколько основных подходов: обучение с учителем, обучение без учителя, обучение с частичным привлечением учителя и обучение с подкреплением. Одним из самых популярных подходов – обучение с учителем, который, в свою очередь, включает в себя методы классификации, регрессии и ранжирования. Типичными являются задачи регрессии и классификации. Регрессия применяется для предсказания непрерывных величин, например, цен на товары. Классификация же применяется при необходимости предсказывания дискретной величины. В данной работе будет рассматриваться задача регрессии.

В основе машинного обучения лежат три компонента:

- Данные

Собираются всевозможными способами. Чем больше собранно данных, тем более эффективным будет машинное обучение.

- Признаки

Определяют, на каких параметрах строится машинное обучение.

- Алгоритм

Алгоритм определяет метод машинного обучения, что влияет на точность, скорость работы и размер готовой модели.

Для решения задачи классификации сравним пять самых популярных моделей машинного обучения: логистическая регрессия, метод ближайших соседей, машина опорных векторов, решающее дерево, случайный лес, а также градиентный бустинг.

Модель логистическая регрессия является самым простым классификатором, на малом объеме данных довольно эффективна и может даже превзойти более сложные методы. Метод ближайших соседей – это простой классификатор с сильно нелинейной границей. Требует запоминания обучающих примеров, а сама классификация происходит по “голосованию” среди K соседей нового объекта ещё не известного класса.

Машина опорных векторов так же является простым линейным вариантом. Алгоритм использует предположение, что чем больше расстояние между разделяющей гиперплоскостью и ближними к ней объектами классов, тем меньше будет средняя ошибка классификатора в последующей работе.

Метод дерева решений представляет собой набор узлов, в каждом из которых принимается решение по одной из переменных, куда двигаться дальше. Удобны в интерпретации (это может быть требованием к алгоритму).

Решающие деревья являются хорошим семейством базовых классификаторов для бэггинга, поскольку они достаточно сложны и могут достигать нулевой ошибки на любой выборке. Метод случайных подпространств позволяет снизить коррелированность между деревьями и избежать переобучения.

Градиентный бустинг объединяет базовые алгоритмы в композицию. Бустинг, использующий деревья решений в качестве базовых алгоритмов, называется градиентным бустингом над решающими деревьями. Он отлично работает на выборках с «табличными», неоднородными данными.

2. Постановка задачи

В данной работе будет решаться задача регрессии на примере цен на различные модели машин Ford.

Таким образом, задача заключается в прогнозировании параметра price. Её решение включается в себя следующие этапы:

1) Проведение разведочного анализа данных. Построение графиков, необходимых для понимания структуры данных. Анализ и заполнение пропусков в данных.
2) Выбор признаков, подходящих для построения моделей. Кодирование категориальных признаков. Масштабирование данных. Формирование вспомогательных признаков, улучшающих качество моделей.
3) Проведение корреляционного анализа данных. Формирование промежуточных выводов о возможности построения моделей машинного обучения.
4) Выбор метрик для последующей оценки качества моделей.

5) Выбор наиболее подходящих моделей для решения задачи регрессии. Необходимо использовать не менее пяти моделей, две из которых должны быть ансамблевыми.
6) Формирование обучающей и тестовой выборок на основе исходного набора данных.
7) Построение базового решения (baseline) для выбранных моделей без подбора гиперпараметров. Производится обучение моделей на основе обучающей выборки и оценка качества моделей на основе тестовой выборки.
8) Подбор гиперпараметров для выбранных моделей. Рекомендуется использовать методы кросс-валидации. В зависимости от используемой библиотеки можно применять функцию GridSearchCV, использовать перебор параметров в цикле, или использовать другие методы.
9) Повторение пункта 8 для найденных оптимальных значений гиперпараметров. Сравнение качества полученных моделей с качеством baseline-моделей.
10) Формирование выводов о качестве построенных моделей на основе выбранных метрик. Результаты сравнения качества рекомендуется отобразить в виде графиков и сделать выводы в форме текстового описания. Рекомендуется построение графиков обучения и валидации, влияния значений гиперпарметров на качество моделей и т.д.

Описание набора данных

В качестве датасета будем использовать набор данных, содержащий данные о характеристиках и ценах на различные модели машин Ford.
https://www.kaggle.com/datasets/adhurimquku/ford-car-price-prediction

Датасет содержит следующие атрибуты:

1. model - > Ford Car Brands - Модели машин марки Ford
2. year - >Production Year - Год выпуска
3. price - >Price of car in $ - Цена машины в долларах
4. transmission - > Automatic,Manual, Semi-Auto - Тип коробки передач: автоматическая, ручная, полуавтоматическая
5. mileage -> Number of miles traveled - Количество пройденных миль
6. fuel_Type -> Petrol,Diesel,Hybrid,Electric,Other - Тип топлива: бензин, дизель, гибрид, электричество, другое
7. tax -> Annual Tax - Ежегодный налог
8. mpg - > Miles per Gallon - Милли на галон
9. engineSize - > Car's Engine Size - Размер двигателя автомобиля

Будем решать задачу регрессии: в качестве целевого признака будем использовать price.

Импорт библиотек

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import MinMaxScaler
from sklearn.preprocessing import LabelEncoder
from sklearn.linear_model import LinearRegression, LogisticRegression
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.metrics import precision_score, recall_score, f1_score, classification_report
from sklearn.metrics import confusion_matrix
from sklearn.metrics import plot_confusion_matrix
from sklearn.model_selection import GridSearchCV
from sklearn.metrics import mean_absolute_error, mean_squared_error, mean_squared_log_erro
from sklearn.metrics import roc_curve, roc_auc_score
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export_graphviz
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
```

```
from sklearn.ensemble import RandomForestClassifier, RandomForestRegressor
from sklearn.ensemble import ExtraTreesClassifier, ExtraTreesRegressor
from sklearn.ensemble import GradientBoostingClassifier, GradientBoostingRegressor
%matplotlib inline
sns.set(style="ticks")
```

Загрузка данных

Монтирование Google Drive для получения доступа к данным, лежащим на нем:

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.m
```

```
filename = '/content/drive/MyDrive/ford.csv'
```

```
train = pd.read_csv(filename, sep=',')
```

```
train.head()
```

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	Fiesta	2017	12000	Automatic	15944	Petrol	150	57.7	1.0
1	Focus	2018	14000	Manual	9083	Petrol	150	57.7	1.0
2	Focus	2017	13000	Manual	12456	Petrol	150	57.7	1.0
3	Fiesta	2019	17500	Manual	10460	Petrol	145	40.3	1.5
4	Fiesta	2019	16500	Automatic	1482	Petrol	145	48.7	1.0

Проведение разведочного анализа данных. Построение графиков, необходимых для понимания структуры данных. Анализ и заполнение пропусков в данных.

Основные характеристики датасета

```
# Первые 5 строк датасета
train.head()
```

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	Fiesta	2017	12000	Automatic	15944	Petrol	150	57.7	1.0
1	Focus	2018	14000	Manual	9083	Petrol	150	57.7	1.0
2	Focus	2017	13000	Manual	12456	Petrol	150	57.7	1.0
3	Fiesta	2019	17500	Manual	10460	Petrol	145	40.3	1.5

```
# Размер датасета - 395 строк, 33 колонки
train.shape
```

```
(17812, 9)
```

```
# Список колонок
train.columns
```

```
Index(['model', 'year', 'price', 'transmission', 'mileage', 'fuelType', 'tax',
       'mpg', 'engineSize'],
      dtype='object')
```

```
# Список колонок с типами данных
train.dtypes
```

```
model            object
year              int64
price             int64
transmission     object
mileage           int64
fuelType         object
tax               int64
mpg             float64
engineSize      float64
dtype: object
```

```
# Проверим наличие пустых значений
train.isnull().sum()
```

```
model           0
year            0
price           0
transmission    0
mileage         0
fuelType        0
tax             0
mpg             0
engineSize      0
dtype: int64
```

В данном наборе данных нет пропусков.

Построение графиков для понимания структуры данных

```
# Парные диаграммы
sns.pairplot(train)
```

```
<seaborn.axisgrid.PairGrid at 0x7f403ff07810>
```


```
# Скрипичные диаграммы для числовых колонок
for col in ['year', 'price', 'mileage', 'tax']:
    sns.violinplot(x=train[col])
    plt.show()
```

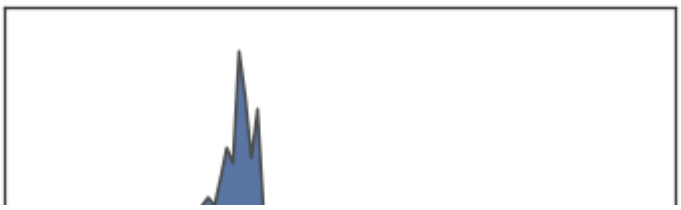

Выбор признаков, подходящих для построения моделей. Кодирование категориальных признаков. Масштабирование данных. Формирование вспомогательных признаков, улучшающих качество моделей.

```
train.dtypes
```

```
model            object
year              int64
price             int64
transmission     object
mileage           int64
fuelType         object
tax               int64
mpg             float64
engineSize      float64
dtype: object
```

Для построения модели будем использовать все признаки.

Кодирование категориальных данных

Категориальные данные находятся в столбцах "model", "fuelType", "transmission". Для кодирования этих столбцов будем использовать LabelEncoder:

```
from sklearn.preprocessing import LabelEncoder
```

```
#model
lemanum = LabelEncoder()
lemanumarr = lemanum.fit_transform(train["model"])
train["model"] = lemanumarr
train = train.astype({"model":"int"})

#transmission
lemot = LabelEncoder()
lemotarr = lemot.fit_transform(train["transmission"])
train["transmission"] = lemotarr
train = train.astype({"transmission":"int"})
```

```
#fuelType
lemof = LabelEncoder()
lemofarr = lemof.fit_transform(train["fuelType"])
train["fuelType"] = lemofarr
train = train.astype({"fuelType":"int"})
```

Выведем новые уникальные значения

```
np.unique(lemanumarr), np.unique(lemotarr), np.unique(lemofarr)
```

```
(array([ 0,  1,  2,  3,  4,  5,  6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16,
        17, 18, 19, 20, 21, 22, 23]), array([0, 1, 2]), array([0, 1, 2, 3, 4]))
```

Выведем обновленную таблицу

```
train.head()
```

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize
0	5	2017	12000	0	15944	4	150	57.7	1.0
1	6	2018	14000	1	9083	4	150	57.7	1.0
2	6	2017	13000	1	12456	4	150	57.7	1.0
3	5	2019	17500	1	10460	4	145	40.3	1.5
4	5	2019	16500	0	1482	4	145	48.7	1.0

```
train.dtypes
```

```
model             int64
year              int64
price             int64
transmission      int64
mileage           int64
fuelType          int64
tax               int64
mpg             float64
engineSize      float64
dtype: object
```

Масштабирование данных

```
# Числовые колонки для масштабирования
scale_cols = ['year', 'mileage', 'tax', 'model', 'transmission', 'fuelType', 'mpg',
              'engineSize']
```

```
sc1 = MinMaxScaler()
```

```
sc1_data = sc1.fit_transform(train[scale_cols])

# Добавим масштабированные данные в набор данных
for i in range(len(scale_cols)):
    col = scale_cols[i]
    new_col_name = col + '_scaled'
    train[new_col_name] = sc1_data[:,i]



train.head()
```

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize	year_s
0	5	2017	12000	0	15944	4	150	57.7	1.0	0.3
1	6	2018	14000	1	9083	4	150	57.7	1.0	0.3
2	6	2017	13000	1	12456	4	150	57.7	1.0	0.3
3	5	2019	17500	1	10460	4	145	40.3	1.5	0.3
4	5	2019	16500	0	1482	4	145	48.7	1.0	0.3

```
# Проверим, что масштабирование не повлияло на распределение данных
for col in scale_cols:
    col_scaled = col + '_scaled'

    fig, ax = plt.subplots(1, 2, figsize=(8,3))
    ax[0].hist(train[col], 50)
    ax[1].hist(train[col_scaled], 50)
    ax[0].title.set_text(col)
    ax[1].title.set_text(col_scaled)
    plt.show()
```

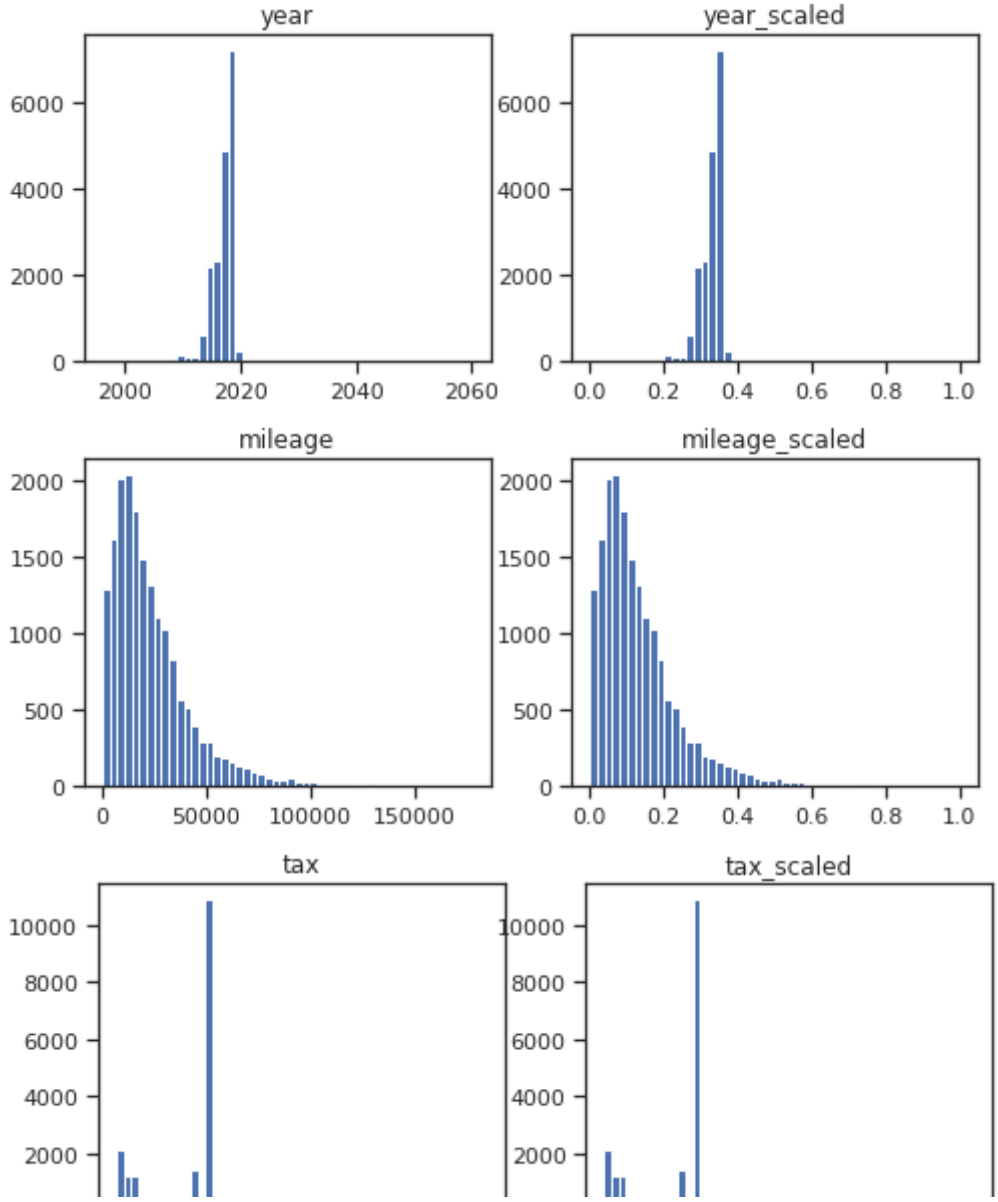

Проведение корреляционного анализа данных.

- Формирование промежуточных выводов о возможности построения моделей машинного обучения.

```
corr_cols_1 = scale_cols + ['price']
corr_cols_1
```

```
['year',
 'mileage',
 'tax',
 'model',
 'transmission',
 'fuelType',
 'mpg',
 'engineSize',
 'price']
```

```
scale_cols_postfix = [x+'_scaled' for x in scale_cols]
```

```
corr_cols_2 = scale_cols_postfix + ['price']
corr_cols_2
```

```
['year_scaled',
 'mileage_scaled',
 'tax_scaled',
 'model_scaled',
 'transmission_scaled',
 'fuelType_scaled',
 'mpg_scaled',
 'engineSize_scaled',
 'price']
```

```
fig, ax = plt.subplots(figsize=(14,7))
sns.heatmap(train[corr_cols_1].corr(), vmin=-1, vmax=1, cmap='coolwarm', annot=True)
ax.set_title('Исходные данные (до масштабирования)')
plt.show()
```

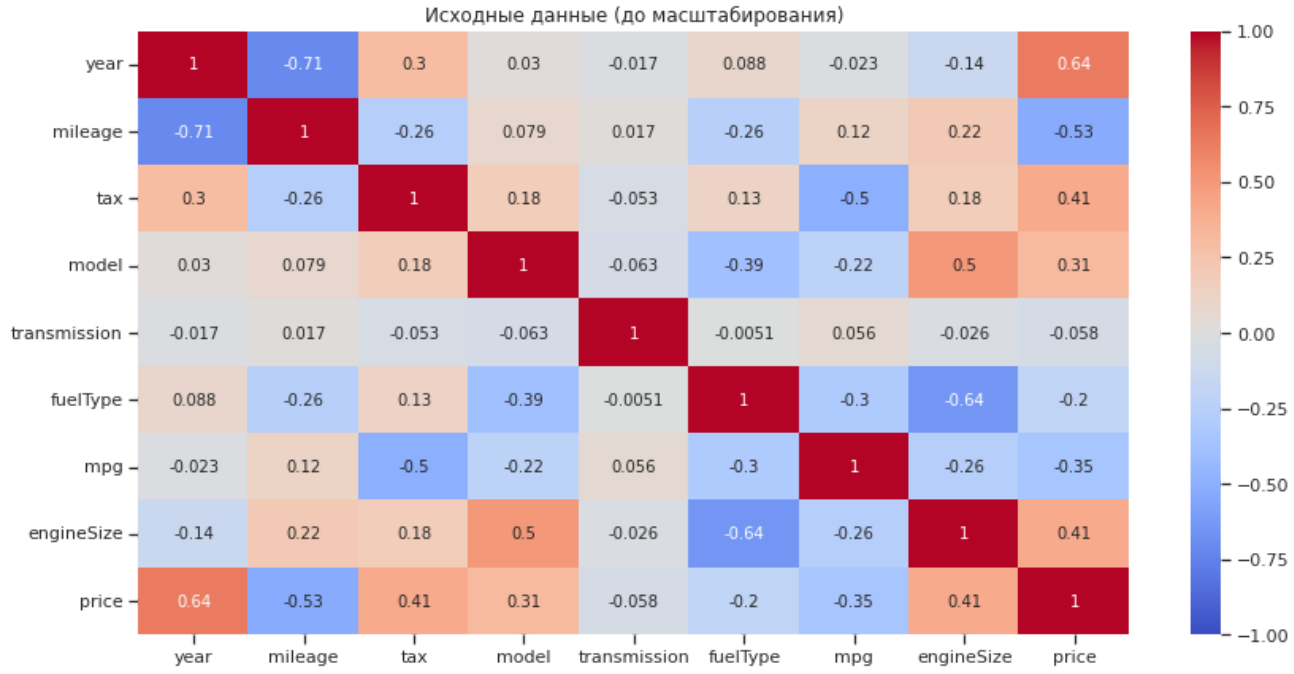


```
fig, ax = plt.subplots(figsize=(14,7))
sns.heatmap(train[corr_cols_2].corr(), vmin=-1, vmax=1, cmap='coolwarm', annot=True)
ax.set_title('Масштабированные данные')
plt.show()
```

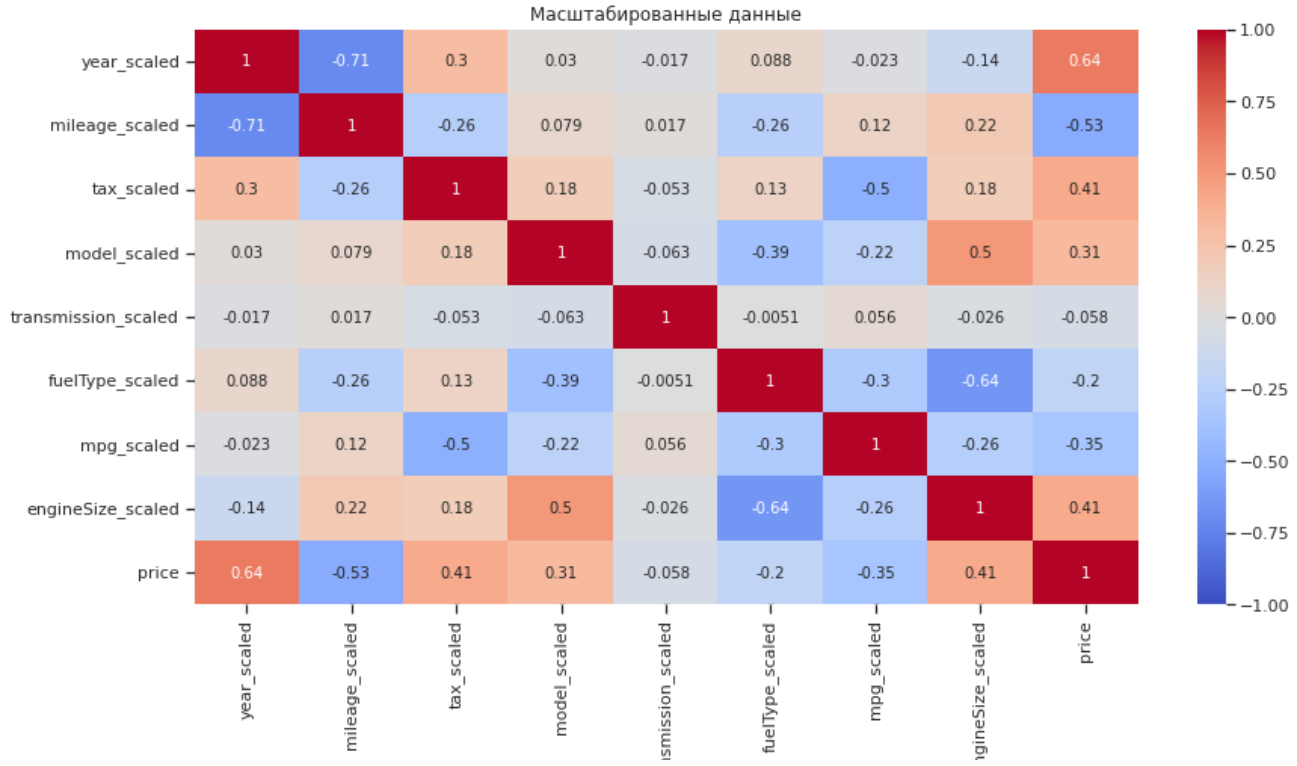


```
print('Признаки, имеющие максимальную по модулю корреляцию с целевым признаком')
best_params = train[corr_cols_1].corr()['price'].map(abs).sort_values(ascending=False)[1:]
best_params = best_params[best_params.values > 0.15]
best_params
```

```
Признаки, имеющие максимальную по модулю корреляцию с целевым признаком
year          0.636009
mileage       0.530659
engineSize    0.411178
tax           0.406857
mpg           0.346419
model         0.314736
fuelType      0.202855
Name: price, dtype: float64
```

На основе корреляционной матрицы можно сделать следующие выводы:

1. Корреляционные матрицы для исходных и масштабированных данных совпадают.
2. Целевой признак регрессии price наиболее сильно коррелирует с годом выпуска машины (0.64) и с колличеством пройденых миль (0.53). Эти признаки обязательно следует оставить в модели классификации.

Выбор метрик для последующей оценки качества моделей.

В качестве метрик для решения задачи регрессии будем использовать:

Mean absolute error - средняя абсолютная ошибка

Чем ближе значение к нулю, тем лучше качество регрессии.

Основная проблема метрики состоит в том, что она не нормирована.

Вычисляется с помощью функции mean_absolute_error.

Mean squared error - средняя квадратичная ошибка

Вычисляется с помощью функции mean_squared_error.

Метрика R^2 или коэффициент детерминации

Вычисляется с помощью функции r2_score.

Сохранение и визуализация метрик

Разработаем класс, который позволит сохранять метрики качества построенных моделей и реализует визуализацию метрик качества.

```
class MetricLogger:

    def __init__(self):
        self.df = pd.DataFrame(
            {'metric': pd.Series([], dtype='str'),
            'alg': pd.Series([], dtype='str'),
            'value': pd.Series([], dtype='float')})

    def add(self, metric, alg, value):
        """
        Добавление значения
        """
        # Удаление значения если оно уже было ранее добавлено
        self.df.drop(self.df[(self.df['metric']==metric)&(self.df['alg']==alg)].index, inp
        # Добавление нового значения
        temp = [{'metric':metric, 'alg':alg, 'value':value}]
        self.df = self.df.append(temp, ignore_index=True)

    def get_data_for_metric(self, metric, ascending=True):
        """
        Формирование данных с фильтром по метрике
        """
        temp_data = self.df[self.df['metric']==metric]
        temp_data_2 = temp_data.sort_values(by='value', ascending=ascending)
        return temp_data_2['alg'].values, temp_data_2['value'].values
```

```
    def plot(self, str_header, metric, ascending=True, figsize=(5, 5)):
        """
        Вывод графика
        """
        array_labels, array_metric = self.get_data_for_metric(metric, ascending)
        fig, ax1 = plt.subplots(figsize=figsize)
        pos = np.arange(len(array_metric))
        rects = ax1.barh(pos, array_metric,
                         align='center',
                         height=0.5,
                         tick_label=array_labels)
        ax1.set_title(str_header)
        for a,b in zip(pos, array_metric):
            plt.text(0.5, a-0.05, str(round(b,3)), color='white')
        plt.show()
```

Выбор наиболее подходящих моделей для решения задачи регрессии.

Для задачи регрессии будем использовать следующие модели:

- Линейная регрессия
- Метод ближайших соседей
- Решающее дерево
- Случайный лес
- Градиентный бустинг

Формирование обучающей и тестовой выборок на основе исходного набора данных.

```
train.head()
```

	model	year	price	transmission	mileage	fuelType	tax	mpg	engineSize	year_s
0	5	2017	12000	0	15944	4	150	57.7	1.0	0.3
1	6	2018	14000	1	9083	4	150	57.7	1.0	0.3
2	6	2017	13000	1	12456	4	150	57.7	1.0	0.3
3	5	2019	17500	1	10460	4	145	40.3	1.5	0.3
4	5	2019	16500	0	1482	4	145	48.7	1.0	0.3

```
# Признаки для задачи регрессии
task_regr_cols = ['year_scaled', 'mileage_scaled', 'engineSize', 'mpg_scaled']
```

```
# Выборки для задачи регресии
y = train['price']
X = train[task_regr_cols]
x_train, x_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=3)
```

```
x_train.shape, x_test.shape, y_train.shape, y_test.shape
```

```
((12576, 4), (5390, 4), (12576,), (5390,))
```

Построение базового решения (baseline) для выбранных моделей без подбора гиперпараметров. Производится обучение моделей на основе обучающей выборки и оценка качества моделей на основе тестовой выборки.

Решение задачи регрессии

```
# Модели
regr_models = {'LR': LinearRegression(),
               'KNN_5':KNeighborsRegressor(n_neighbors=5),
               'SVR':SVR(),
               'Tree':DecisionTreeRegressor(),
               'RF':RandomForestRegressor(),
               'GB':GradientBoostingRegressor()}
```

```
# Сохранение метрик
regrMetricLogger = MetricLogger()
```

```
def regr_train_model(model_name, model, regrMetricLogger):
    model.fit(x_train, y_train)
    Y_pred = model.predict(x_test)

    mae = mean_absolute_error(y_test, Y_pred)
    mse = mean_squared_error(y_test, Y_pred)
    r2 = r2_score(y_test, Y_pred)

    regrMetricLogger.add('MAE', model_name, mae)
    regrMetricLogger.add('MSE', model_name, mse)
    regrMetricLogger.add('R2', model_name, r2)

    print('{} \t MAE={}, MSE={}, R2={}'.format(
        model_name, round(mae, 3), round(mse, 3), round(r2, 3)))
```

```
for model_name, model in regr_models.items():
```

```
regr_train_model(model_name, model, regrMetricLogger)
```

```
LR       MAE=1743.294, MSE=5669341.277, R2=0.732
KNN_5    MAE=1051.973, MSE=2427528.982, R2=0.885
SVR      MAE=3399.929, MSE=20036371.304, R2=0.053
Tree     MAE=1218.746, MSE=3333097.426, R2=0.843
RF       MAE=1023.047, MSE=2279963.966, R2=0.892
GB       MAE=1109.199, MSE=2519748.727, R2=0.881
```

Подбор гиперпараметров для выбранных моделей.

Линейная регрессия

```
x_train.shape
```

```
(12576, 4)
```

```
print(LinearRegression().get_params().keys())
```

```
dict_keys(['copy_X', 'fit_intercept', 'n_jobs', 'normalize', 'positive'])
```

```
%%time
grid={'n_jobs':np.logspace(-3,3,3)}
regr_gs_LR = GridSearchCV(LinearRegression(), grid, cv=5, scoring='neg_mean_squared_error'
regr_gs_LR.fit(x_train, y_train)
```

```
CPU times: user 149 ms, sys: 82.8 ms, total: 232 ms
Wall time: 209 ms
```

```
regr_gs_LR.best_estimator_
```

```
LinearRegression(n_jobs=0.001)
```

```
regr_gs_LR.best_params_
```

```
{'n_jobs': 0.001}
```

```
plt.plot(np.logspace(-3,3,3), regr_gs_LR.cv_results_['mean_test_score'])
```

```
[<matplotlib.lines.Line2D at 0x7f403e199810>]
```

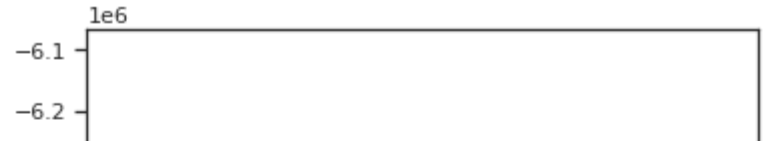

Метод ближайших соседей

```
print(KNeighborsRegressor().get_params().keys())
```

```
dict_keys(['algorithm', 'leaf_size', 'metric', 'metric_params', 'n_jobs', 'n_neighbor
```

```
n_range = np.array(range(1,220,1))
tuned_parameters = [{'n_neighbors': n_range}]
tuned_parameters
```

```
[{'n_neighbors': array([  1,   2,   3,   4,   5,   6,   7,   8,   9,  10,  11,  12,
          14,  15,  16,  17,  18,  19,  20,  21,  22,  23,  24,  25,  26,
          27,  28,  29,  30,  31,  32,  33,  34,  35,  36,  37,  38,  39,
          40,  41,  42,  43,  44,  45,  46,  47,  48,  49,  50,  51,  52,
          53,  54,  55,  56,  57,  58,  59,  60,  61,  62,  63,  64,  65,
          66,  67,  68,  69,  70,  71,  72,  73,  74,  75,  76,  77,  78,
          79,  80,  81,  82,  83,  84,  85,  86,  87,  88,  89,  90,  91,
          92,  93,  94,  95,  96,  97,  98,  99, 100, 101, 102, 103, 104,
         105, 106, 107, 108, 109, 110, 111, 112, 113, 114, 115, 116, 117,
         118, 119, 120, 121, 122, 123, 124, 125, 126, 127, 128, 129, 130,
         131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 142, 143,
         144, 145, 146, 147, 148, 149, 150, 151, 152, 153, 154, 155, 156,
         157, 158, 159, 160, 161, 162, 163, 164, 165, 166, 167, 168, 169,
         170, 171, 172, 173, 174, 175, 176, 177, 178, 179, 180, 181, 182,
         183, 184, 185, 186, 187, 188, 189, 190, 191, 192, 193, 194, 195,
         196, 197, 198, 199, 200, 201, 202, 203, 204, 205, 206, 207, 208,
         209, 210, 211, 212, 213, 214, 215, 216, 217, 218, 219])}]
```

```
%%time
regr_gs = GridSearchCV(KNeighborsRegressor(), tuned_parameters, cv=5, scoring='neg_mean_sq
regr_gs.fit(x_train, y_train)
```

```
CPU times: user 2min 14s, sys: 334 ms, total: 2min 14s
Wall time: 2min 14s
```

```
# Лучшая модель
regr_gs.best_estimator_
```

```
KNeighborsRegressor(n_neighbors=7)
```

```
# Лучшее значение параметров
regr_gs.best_params_
```

```
{'n_neighbors': 7}
```

```
regr_gs_best_params_txt = str(regr_gs.best_params_['n_neighbors'])
regr_gs_best_params_txt
```

```
'7'
```

```
# Изменение качества на тестовой выборке в зависимости от K-соседей
plt.plot(n_range, regr_gs.cv_results_['mean_test_score'])
```

```
[<matplotlib.lines.Line2D at 0x7f403dbcb390>]
```

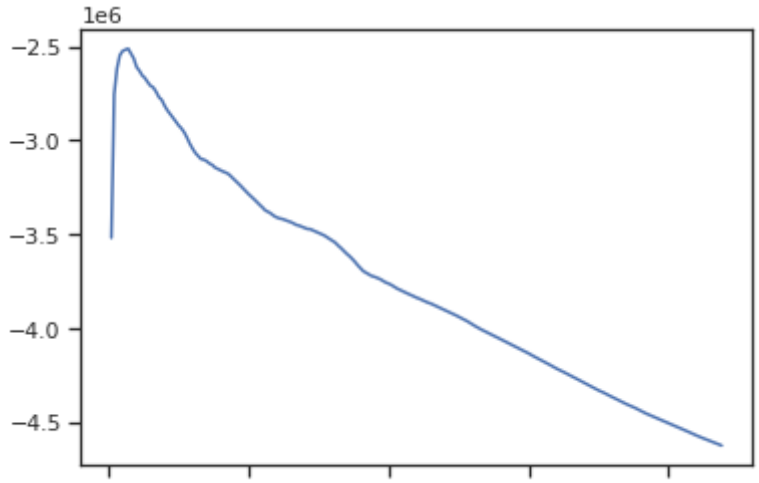

Решающее дерево

```
print(DecisionTreeRegressor().get_params().keys())
```

```
dict_keys(['ccp_alpha', 'criterion', 'max_depth', 'max_features', 'max_leaf_nodes',
```

```
params = {"max_depth":range(1,20), "max_features":range(1,5)}

Tree_gs = GridSearchCV(DecisionTreeRegressor(), params, cv=5, scoring='neg_mean_squared_er
Tree_gs.fit(x_train, y_train)
```

```
GridSearchCV(cv=5, estimator=DecisionTreeRegressor(),
             param_grid={'max_depth': range(1, 20),
                         'max_features': range(1, 5)},
             scoring='neg_mean_squared_error')
```

```
# Лучшая модель
Tree_gs.best_estimator_
```

```
DecisionTreeRegressor(max_depth=11, max_features=3)
```

```
# Лучшее значение параметров
Tree_gs.best_params_
```

Градиентный бустинг

```
print(GradientBoostingRegressor().get_params().keys())
```

```
dict_keys(['alpha', 'ccp_alpha', 'criterion', 'init', 'learning_rate', 'loss', 'max_d
```

```
GB_params={"max_features":range(1,5), "max_leaf_nodes":range(2,22)}
GB_gs = GridSearchCV(GradientBoostingRegressor(), GB_params, cv=5, scoring='neg_mean_squar
GB_gs.fit(x_train, y_train)
```

```
GridSearchCV(cv=5, estimator=GradientBoostingRegressor(),
             param_grid={'max_features': range(1, 5),
                         'max_leaf_nodes': range(2, 22)},
             scoring='neg_mean_squared_error')
```

```
# Лучшее значение параметров
GB_gs.best_params_
```

```
{'max_features': 3, 'max_leaf_nodes': 19}
```

Случайный лес

```
print(RandomForestRegressor().get_params().keys())
```

```
dict_keys(['bootstrap', 'ccp_alpha', 'criterion', 'max_depth', 'max_features', 'max_l
```

```
RF_params={"max_leaf_nodes":range(2,12), "max_samples":range(2,22)}
RF_gs = GridSearchCV(RandomForestRegressor(), RF_params, cv=5, scoring='neg_mean_squared_e
RF_gs.fit(x_train, y_train)
```

```
GridSearchCV(cv=5, estimator=RandomForestRegressor(),
             param_grid={'max_leaf_nodes': range(2, 12),
                         'max_samples': range(2, 22)},
             scoring='neg_mean_squared_error')
```

```
# Лучшая модель
RF_gs.best_estimator_
```

```
RandomForestRegressor(max_leaf_nodes=9, max_samples=21)
```

Сравнение качества полученных моделей с качеством baseline-моделей.

```
models_grid = { 'LinR_new':regr_gs_LR.best_estimator_,
                'KNN_new':regr_gs.best_estimator_,
```

```
                'Tree_new':Tree_gs.best_estimator_,
                 'RF_new':RF_gs.best_estimator_,
                'GB_new':GB_gs.best_estimator_
                }

for model_name, model in models_grid.items():
    regr_train_model(model_name, model, regrMetricLogger)
```

```
 LinR_new         MAE=1743.294, MSE=5669341.277, R2=0.732
 KNN_new          MAE=1045.929, MSE=2373687.943, R2=0.888
 Tree_new         MAE=1016.235, MSE=2440876.267, R2=0.885
 RF_new   MAE=1855.286, MSE=6639916.724, R2=0.686
 GB_new   MAE=1108.471, MSE=2507695.259, R2=0.882
```

Формирование выводов о качестве построенных моделей на основе выбранных метрик.

```
# Метрики качества модели
regr_metrics = regrMetricLogger.df['metric'].unique()
regr_metrics
```

```
array(['MAE', 'MSE', 'R2'], dtype=object)
```

```
regrMetricLogger.plot('Метрика: ' + 'MAE', 'MAE', ascending=False, figsize=(7, 6))
```

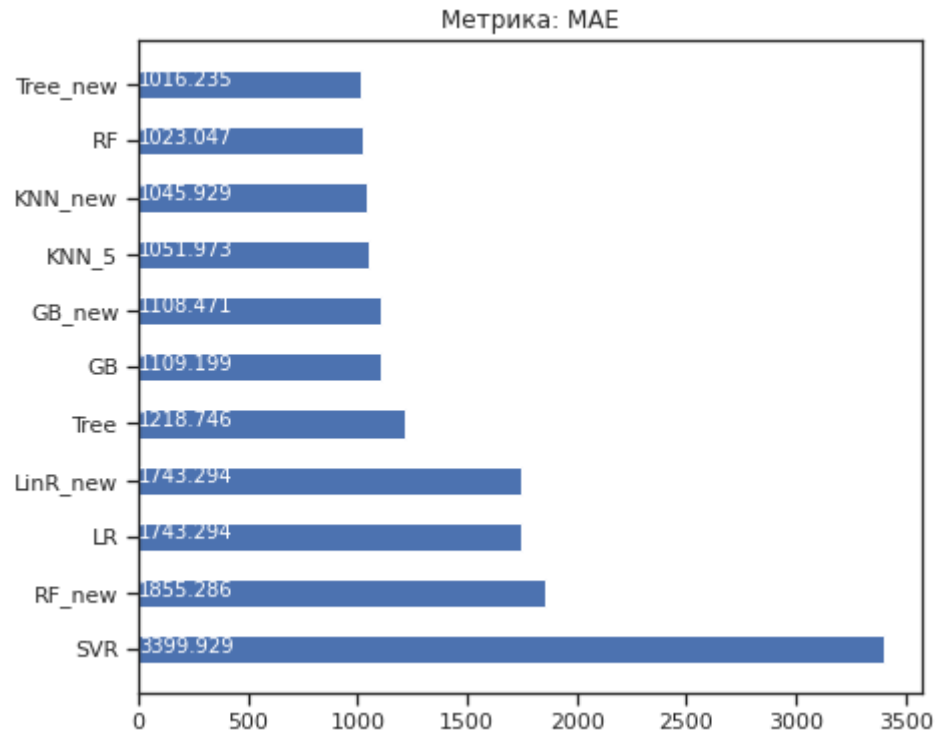


```
regrMetricLogger.plot('Метрика: ' + 'MSE', 'MSE', ascending=False, figsize=(7, 6))
```

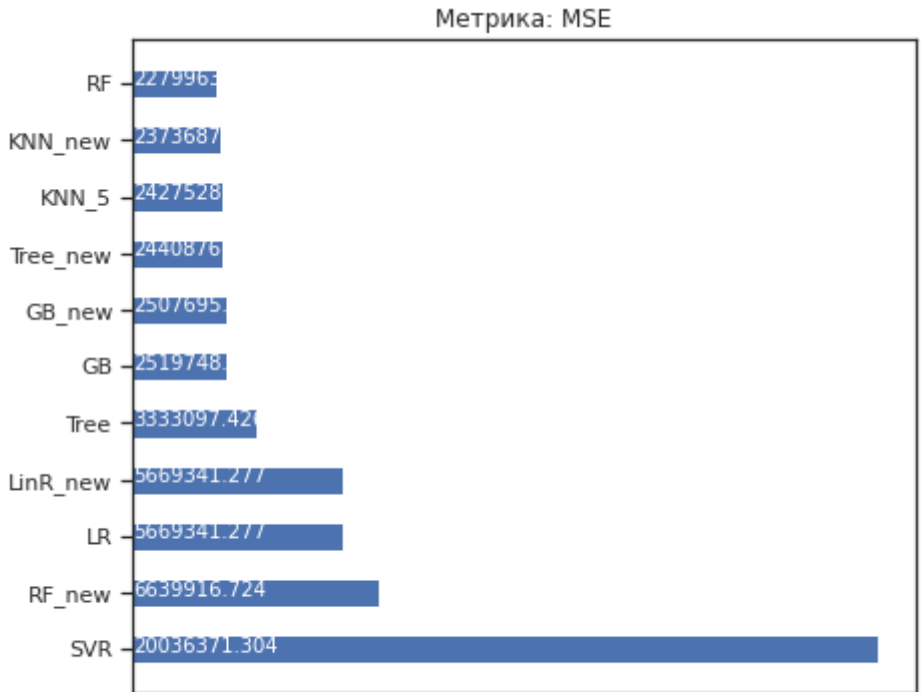


```
regrMetricLogger.plot('Метрика: ' + 'R2', 'R2', ascending=True, figsize=(7, 6))
```

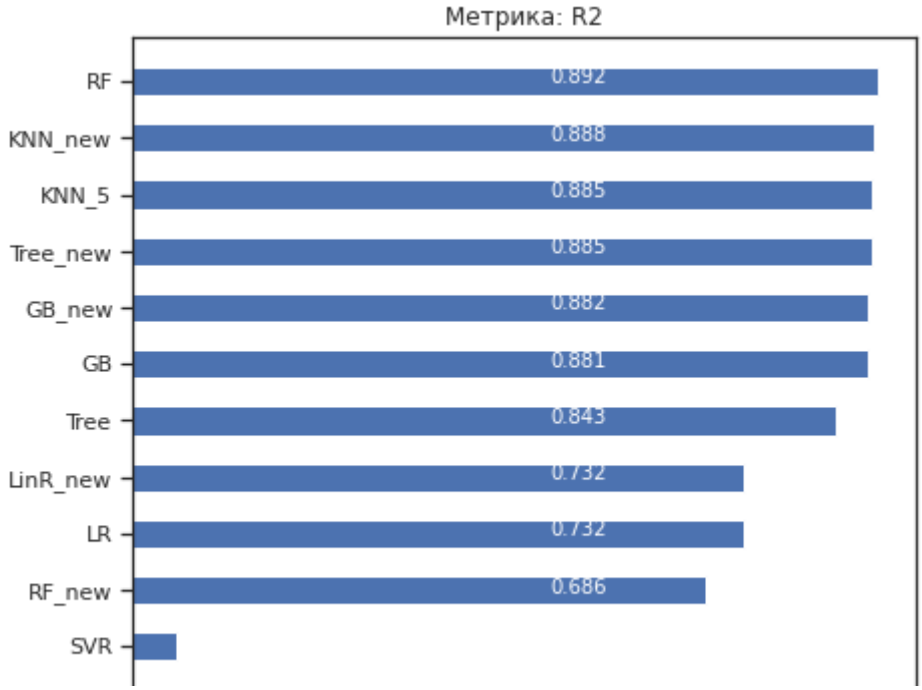

Вывод: лучшими оказались модели на основе близжайших соседей и случаного леса. При отдельных запусках вместо градиентного бустинга оказывается лучшей модель опорных векторов.

5. Заключение

В результате проделанной работы была решена задача машинного обучения. Построены пять моделей машинного обучения, в том числе ансамблевые, для решения задачи регрессии: линейная регрессия, метод ближайших соседей, машина опорных векторов, решающее дерево, случайный лес, градиентный бустинг.

Построено базовое решение для выбранных моделей без подбора гиперпараметров и решение для найденных оптимальных значений гиперпараметров.

Проведено сравнение качества полученных оптимальных моделей с качеством baseline-моделей. Сделаны выводы по качеству построенных моделей на основе метрик MAE, MSE, R^2.

6. Список литературы

1. Кафтанников И.Л., Парасич А.В. Особенности применения деревьев решений в задачах классификации [Текст] / Кафтанников И.Л., Парасич А.В., 2015. – 7 с.
2. Клячкин В.Н., Кувайскова Ю.Е., Жуков Д.А. Выбор метода бинарной классификации при технической диагностике с применением машинного обучения [Текст]: / Клячкин В.Н., Кувайскова Ю.Е., Жуков Д.А, 2018. – 4 с.
3. Картиев С.Б., Курейчик В.М. Алгоритм классификации, основанный на принципах случайного леса, для решения задачи прогнозирования [Текст] / Картиев С.Б., Курейчик В.М. / 2016. – 5 с.