Рубежный контроль №1

Столярова О.Д. РТ5-61Б Вариант 16: Задача 2 Датасет 8

Технологии разведочного анализа и обработки данных

Задача №2.

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

Датасет: https://www.kaggle.com/datasets/mathan/fifa-2018-match-statistics

Predict FIFA 2018 Man of the Match - Прогноз Человека Матча ФИФА в 2018

Данные собраны из официального приложения Чемпионата мира по футболу 2018 года в России.

Импорт библиотек

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Монтирование Google Drive для получения доступа к данным, лежащим на нем:

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Mounted at /content/drive
```

Загрузка данных:

```
filename = '/content/drive/MyDrive/FIFA.csv'

df = pd.read_csv(filename, sep=',')
```

Общая информация о данных

Размер датасета:

```
df.shape
```

```
(128, 27)
```

Колонки датасета:

```
df.columns
```

```
Index(['Date', 'Team', 'Opponent', 'Goal Scored', 'Ball Possession %',
       'Attempts', 'On-Target', 'Off-Target', 'Blocked', 'Corners', 'Offsides',
       'Free Kicks', 'Saves', 'Pass Accuracy %', 'Passes',
       'Distance Covered (Kms)', 'Fouls Committed', 'Yellow Card',
       'Yellow & Red', 'Red', 'Man of the Match', '1st Goal', 'Round', 'PSO',
       'Goals in PSO', 'Own goals', 'Own goal Time'],
      dtype='object')
```

Типы данных колонок:

```
df.dtypes
```

```
Date                     object
Team                     object
Opponent                 object
Goal Scored               int64
Ball Possession %         int64
Attempts                  int64
On-Target                 int64
Off-Target                int64
Blocked                   int64
Corners                   int64
Offsides                  int64
Free Kicks                int64
Saves                     int64
Pass Accuracy %           int64
Passes                    int64
Distance Covered (Kms)    int64
Fouls Committed           int64
Yellow Card               int64
Yellow & Red              int64
Red                       int64
Man of the Match         object
1st Goal                float64
```

```
Round                    object
PSO                      object
Goals in PSO              int64
Own goals               float64
Own goal Time           float64
dtype: object
```

Первые 5 строк датасета:

```
df.head()
```

	Date	Team	Opponent	Goal Scored	Ball Possession %	Attempts	On-Target	Off-Target	Blocked	Cc
0	14-06-2018	Russia	Saudi Arabia	5	40	13	7	3	3	
1	14-06-2018	Saudi Arabia	Russia	0	60	6	0	3	3	
2	15-06-2018	Egypt	Uruguay	0	43	8	3	3	2	
3	15-06-2018	Uruguay	Egypt	1	57	14	4	6	4	
4	15-06-2018	Morocco	Iran	0	64	13	3	6	4	

5 rows × 27 columns

Проверка пропущенных значений:

```
df.isnull().sum()
```

```
Date                    0
Team                    0
Opponent                0
Goal Scored             0
Ball Possession %       0
Attempts                0
On-Target               0
Off-Target              0
Blocked                 0
Corners                 0
Offsides                0
Free Kicks              0
Saves                   0
```

```
Pass Accuracy %            0
Passes                     0
Distance Covered (Kms)     0
Fouls Committed            0
Yellow Card                0
Yellow & Red               0
Red                        0
Man of the Match           0
1st Goal                  34
Round                      0
PSO                        0
Goals in PSO               0
Own goals                116
Own goal Time            116
dtype: int64
```

Построим для пары произвольных колонок данных график "Jointplot"

Комбинация гистограмм и диаграмм рассеивания:

```
sns.jointplot(x='Corners', y='Goal Scored', data=df, height = 7)
```

```
<seaborn.axisgrid.JointGrid at 0x7f76f0e51c90>
```

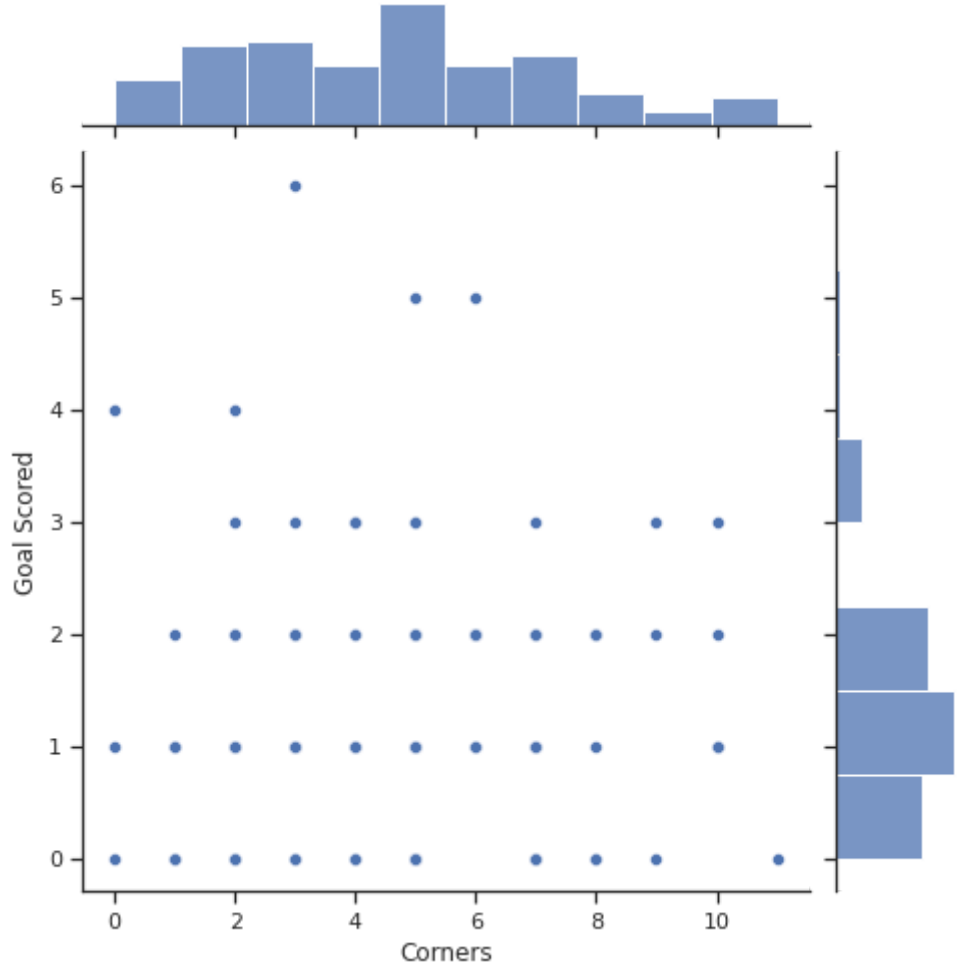

Обработка пропусков

С помощью цикла по колонкам датасета выберем колонки с пропущенными значениями:

```
num_cols = []
total_count = df.shape[0]
for col in df.columns:
    # Количество пустых значений
    temp_null_count = df[df[col].isnull()].shape[0]
    dt = str(df[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col,
```

```
Колонка 1st Goal. Тип данных float64. Количество пустых значений 34, 26.56%.
Колонка Own goals. Тип данных float64. Количество пустых значений 116, 90.62%.
Колонка Own goal Time. Тип данных float64. Количество пустых значений 116, 90.62%.
```

Выведем только колонки с пропущенными значениями:

```
df_num = df[num_cols]
df_num
```

	1st Goal	Own goals	Own goal Time
0	12.0	NaN	NaN
1	NaN	NaN	NaN
2	NaN	NaN	NaN
3	89.0	NaN	NaN
4	NaN	1.0	90.0
...	...	...	...
123	5.0	NaN	NaN
124	4.0	NaN	NaN
125	NaN	NaN	NaN
126	18.0	1.0	18.0
127	28.0	NaN	NaN

128 rows × 3 columns

Пропусков в категориальных колонках нет.

Гистограммы по признакам:

```
for col in df_num:
    plt.hist(df[col], 50)
    plt.xlabel(col)
    plt.show()
```

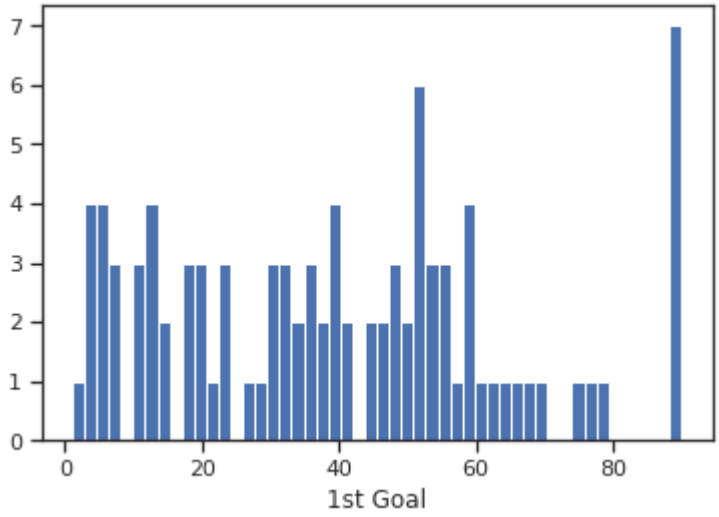

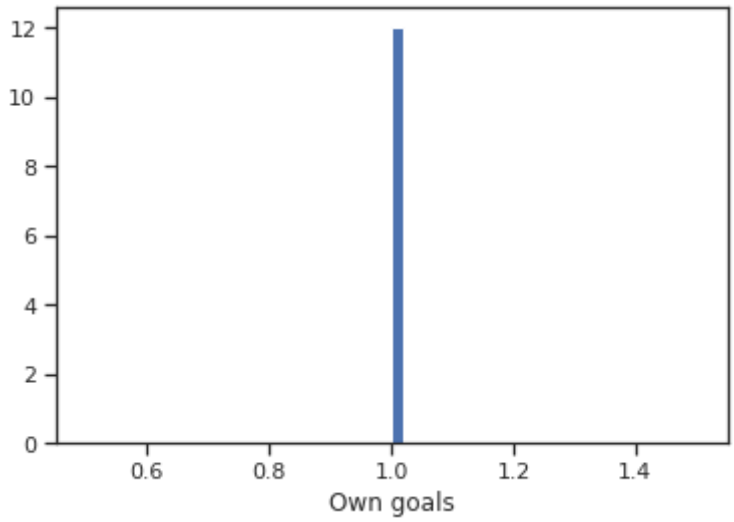

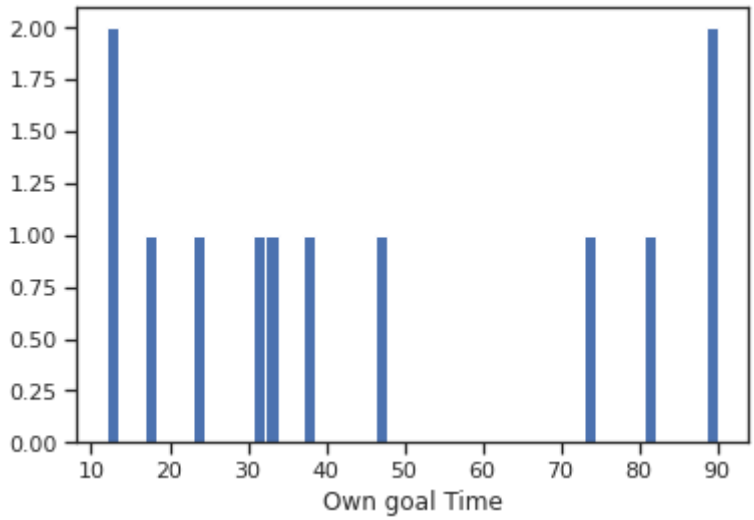

Для заполнения пропусков возьмем колонку 1st Goal - время первого гола

```
df_goal = df_num[['1st Goal']]
df_goal.head()
```

	1st Goal
0	12.0
1	NaN
2	NaN
3	89.0
4	NaN

"Внедрение значений" - импьютация (imputation)

С помощью класса SimpleImputer можно проводить импьютацию различными показателями центра распределения

```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator


# Фильтр для проверки заполнения пустых значений
indicator = MissingIndicator()
mask_missing_values_only = indicator.fit_transform(df_goal)
mask_missing_values_only
```

```
array([[False],
       [ True],
       [ True],
       [False],
       [ True],
       [False],
       [False],
       [False],
       [False],
       [False],
       [False],
       [False],
       [False],
       [ True],
       [False],
       [False],
       [ True],
       [ True],
       [False],
       [ True],
       [False],
       [False],
       [False],
       [False],
       [ True],
       [False],
       [ True],
       [False],
       [False],
       [False],
       [False],
```

```
               [False],
               [False],
               [False],
               [False],
               [False],
               [ True],
               [False],
               [ True],
               [ True],
               [False],
               [False],
               [False],
               [False],
               [ True],
               [ True],
               [False],
               [False],
               [ True],
               [False],
               [ True],
               [False],
               [False],
               [False],
               [False],
               [False],
               [False],
               [False],
               [False],
```

```
strategies=['mean', 'median', 'most_frequent']


def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(df_goal)
    return data_num_imp[mask_missing_values_only]


sns.set(rc={"figure.figsize":(12, 6)})
sns.histplot(data=df['1st Goal'])
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f76ef933d10>
```

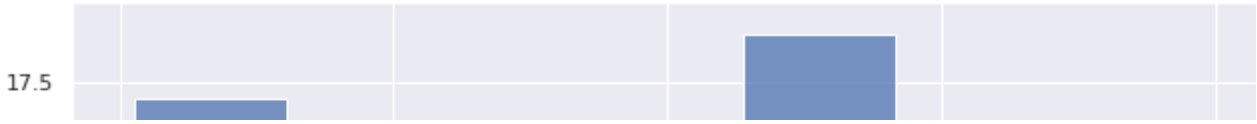

Заполним ее с применением различных стратегий

```
# Заполнение средним
mean_imp = SimpleImputer(strategy='mean')
tot_exp_mean = mean_imp.fit_transform(df[['1st Goal']])
sns.histplot(data=tot_exp_mean)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f76ef8b78d0>
```

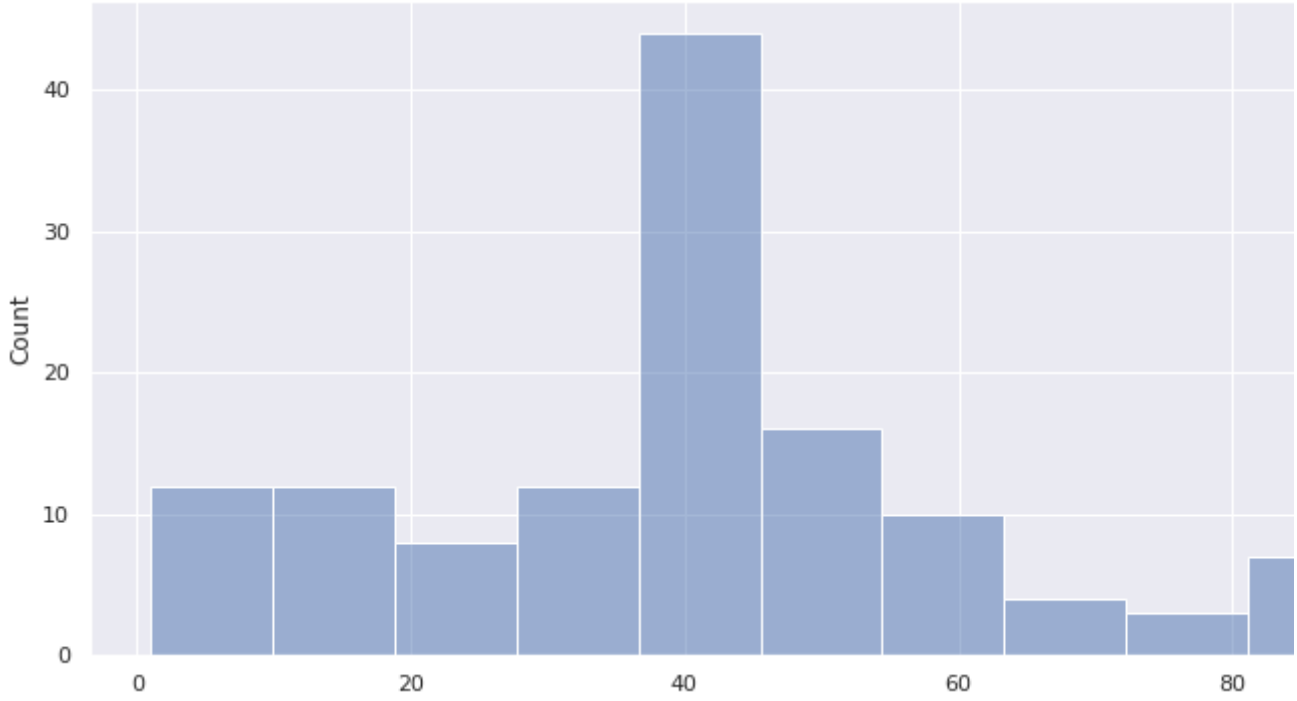


```
# Заполнение медианой
median_imp = SimpleImputer(strategy='median')
tot_exp_mean = median_imp.fit_transform(df[['1st Goal']])
sns.histplot(data=tot_exp_mean)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f76ef83ec50>
```

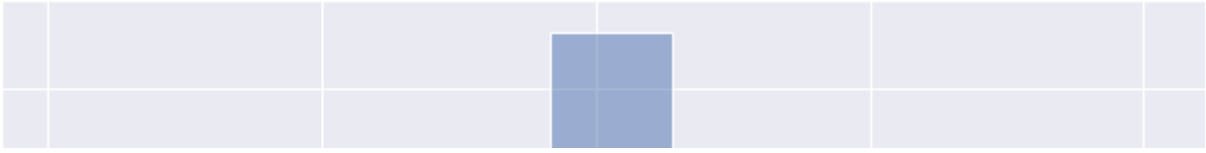


```
# Заполнение модой
most_freq_imp = SimpleImputer(strategy='most_frequent')
tot_exp_mean = most_freq_imp.fit_transform(df[['1st Goal']])
sns.histplot(data=tot_exp_mean)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f76ef8dd8d0>
```

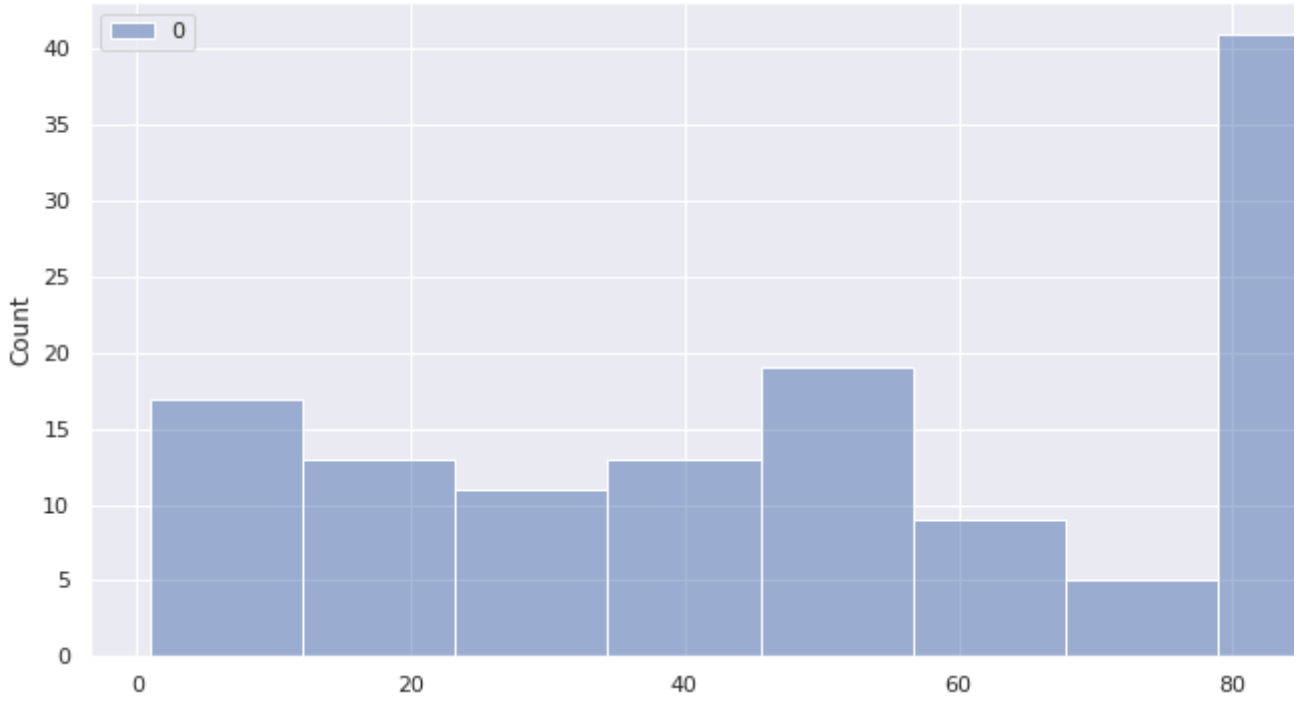

В данном задании для обработки пропусков использован класс SimpleImputer. Он позволяет заполнить данные путем реализации разных стратегий, в данном случае: средним, медианой и модой.

Для заполнения пропусков в категориальных признаках также используется класс SimpleImputer, только в этом случае он реализует стратегии most frequent (заполнение самым часто встречаемым значением) и constant (заполнение некторой константой).

Признаки с большим колличеством пропусков не подходят для дальнейшего построения моделей машинного обучения, такие как 1st Goal, Own goals, Own goal Time. Все остальные признаки подходят для дальнейшей работы, так как в них нет пропусков.